

ME5400 课程项目技术报告

基于 FAST-LIO、PointPillars 与 MCTrack 的动态场景双向协同定位跟踪系统

ME5400 Project

2026 年 4 月 12 日

摘要

本报告围绕 ME5400 课程项目，按照“引言背景、系统框架、代码设计、动态权重优化、联合后端优化、实验分析、结论与未来计划”的结构，对当前仓库中的完整系统实现进行系统整理。项目以 FAST-LIO 作为激光惯导定位前端，以 PointPillars 提供 3D 检测，以 MCTrack 提供多目标跟踪与速度估计，并将跟踪结果反向反馈给 FAST-LIO 进行动态点自适应降权，再进一步送入 ego-only 联合后端修正自车轨迹。报告正文既保留原有的系统背景和工程实现细节，也统一纳入当前 **Results/** 目录中的全部实验结果：在线覆盖 9 个序列 (0003、0006、0007、0009、0010、0012、0013、0017、0020)，离线覆盖 2 个序列 (0009、0020)，并在附录中插入所有现有结果图。结果表明，当前最稳定的收益来自“FAST-LIO 位姿辅助 MCTrack + MCTrack 反哺动态权重”这一前端闭环：在线模式下 FAST-LIO+MCTrack 在 9/9 个序列上均优于基线，ATE RMSE 平均改善 18.00%；而当前 ego-only 联合后端虽可在部分序列上继续抑制全局漂移，但稳定性仍弱于前端闭环本身。该系统已经形成了一条可运行、可重放、可视化、可量化评估的工程验证链路，也为后续 object-centric LiDAR-inertial 联合优化提供了可直接扩展的基础。

关键词： FAST-LIO；PointPillars；MCTrack；动态场景 SLAM；多目标跟踪；联合优化；ROS

1 引言与背景 (Introduction / Background)

动态道路场景下的定位与感知，本质上存在一组长期对立的需求。对于激光 SLAM 或 LiDAR-inertial odometry 而言，系统希望环境中的大部分几何结构是静态、可重复观测且可长期复用的；然而对于自动驾驶或移动机器人感知系统而言，道路中的车辆、行人和骑行者又恰恰是最重要的动态目标。这些目标会在点云中形成随时间变化的几

何结构：如果将其直接当作静态点写入地图和配准残差，系统就会出现鬼影、局部错配和累计漂移；如果一律硬剔除，又会连同一部分潜在可用的几何信息一并删除，导致在静态结构稀疏、视角变化剧烈或高速运动场景下约束不足。

多目标跟踪 (MOT) 系统面临的是与之相反但同样困难的问题。3D 检测框的跨帧关联极大依赖自车位姿的稳定补偿。如果跟踪器无法获得足够准确且高频的自车位姿，检测框之间的几何关系就会被自车运动扰乱，导致轨迹中断、速度估计抖动和 ID 切换。于是，定位系统和跟踪系统并非简单的串联关系，而是天然存在双向依赖：定位越准确，跟踪越稳定；跟踪越稳定，系统越能识别哪些点来自运动目标，从而反向帮助建图与定位。

本项目正是沿着这一思路展开。它不是把 FAST-LIO、PointPillars 与 MCTrack 机械地串起来，而是围绕“让定位帮助跟踪，让跟踪反哺定位”构造一条闭环协同管线。原始 KITTI Tracking rosbag 提供 LiDAR 与 IMU；PointPillars 给出三维检测框；FAST-LIO 给出优化位姿和 IMU 预测位姿；MCTrack 结合位姿与检测完成在线跟踪；跟踪结果一方面反馈给 FAST-LIO 做动态点降权，另一方面进入联合后端修正自车轨迹。这样一来，动态目标不再只是被过滤掉的噪声，而是开始参与前端权重调节和后端优化。

从更宽的研究背景看，近期动态场景 SLAM / SLAMMOT 工作普遍在向“定位与跟踪共享信息”演进，但大多数方法仍主要关注动态点过滤、目标状态估计或隐式数据关联，而较少真正把动态物体转化为帮助自车定位的几何参照。本项目当前版本依然是一个工程型、松耦合原型，而不是最终形态的紧耦合因子图系统；但它已经完成了完整的信息闭环、统一脚本管理、可视化验证和多序列结果归档，因此具有明确的课程项目价值，也具备继续向 object-centric 联合优化扩展的现实基础。

1.1 研究现状分析

为把本项目放到当前研究脉络中，本文进一步选取 `slammot_comparison.md` 中整理的 5 篇近期代表性工作作为对照：Conf SLAMMOT (*LiDAR SLAMMOT based on Confidence-guided Data Association*)、LIMOT (*A Tightly-Coupled System for LiDAR-Inertial Odometry and Multi-Object Tracking*)、IMM-SLAMMOT (*Visual SLAMMOT Considering Multiple Motion Models*)、Online Dynamic SLAM (*Online Dynamic SLAM with Incremental Smoothing and Mapping*) 以及 DL-SLOT (*Tightly-Coupled Dynamic LiDAR SLAM and 3D Object Tracking Based on Collaborative Graph Optimization*)。这些工作覆盖了 LiDAR、LiDAR+IMU 和双目视觉三类传感器路线，也覆盖了滑窗图优化、Bundle Adjustment 和 iSAM2 增量优化等典型实现路径。

表 1: 近期动态场景 SLAMMOT 代表工作与本项目定位

工作	传感器与前端	耦合与优化方式	核心特征及对本项目的启发
Conf SLAM-MOT	LiDAR; LiDAR 里程计前端	紧耦合; 置信度引导的数据关联嵌入图优化	强调把检测/关联置信度直接写进联合优化过程, 可为本项目后续对象因子加权提供思路。
LIMOT	LiDAR+IMU; 自研 LIO 前端	紧耦合; 滑动窗口因子图	代表了 LiDAR-inertial 与 MOT 统一建模的主流方向, 对本项目从 topic 级松耦合走向统一状态优化最具参考价值。
IMM-SLAMMOT	双目视觉; ORB-SLAM2 前端	紧耦合; BA 联合优化 + 多运动模型	突出复杂动态目标的多模型切换能力, 说明仅靠单一恒速假设难以覆盖真实交通场景。
Online Dynamic SLAM	双目视觉; 自研 VO 前端	紧耦合; iSAM2 增量平滑与建图	重点解决在线动态场景下的实时优化问题, 说明增量式后端对实时系统可扩展性非常关键。
DL-SLOT	LiDAR; LiDAR 里程计前端	紧耦合; 协同图优化 / 滑窗优化	体现了 LiDAR 路线中“检测、跟踪、定位”共享窗口信息的趋势, 对本项目联合后端的窗口管理和边缘化策略有直接借鉴意义。

从上述工作可以归纳出三点研究现状。第一，**系统结构正从级联式管线快速转向紧耦合图优化**。这 5 篇论文几乎都不再把 SLAM 和 MOT 当成完全独立的黑盒模块，而是尝试共享位姿、目标状态、关联置信度或运动模型，使前后端能够在同一优化窗口内互相修正。第二，**动态目标的利用方式仍以“过滤、关联、联合估计”为主**。现有方法虽然已经开始把目标速度、轨迹长度、检测置信度等信息纳入推理，但大多数仍停留在动态点剔除、动态目标状态估计或隐式关联加权层面，还没有真正把动态车辆的刚体几何特性显式转化为 LiDAR-inertial 定位约束。第三，**实时性与工程落地已成为评价系统价值的重要指标**。无论是 LIMOT、DL-SLOT 的滑窗方案，还是 Online Dynamic SLAM 的 iSAM2 增量式路线，都说明研究系统不能只强调精度，还必须考虑在线运行、窗口管理和可扩展部署。

与这些工作相比，本项目当前版本的定位是“工程闭环已经跑通，但统一优化仍处于原型阶段”。它的优势在于：FAST-LIO 前端成熟稳定，PointPillars 与 MCTrack 已在 ROS 中完成完整接入，动态权重闭环已经在多序列上验证有效；它的不足在于：SLAM 与 MOT 仍主要通过 topic 交互而非共享状态图耦合，联合后端也还停留在 ego-only 形式。换言之，本项目已经具备了继续升级为紧耦合 SLAMMOT 系统的基础设施，而后续最有研究价值的推进方向，正是把 MCTrack 的目标置信度、速度与轨迹稳定性进一步写入统一因子图，并探索利用动态目标刚体约束把“干扰源”转化为“移动路标”。

2 整体系统框架图、PointPillars / MCTrack 与数据流




图 1: 系统总体架构。整个系统可分为前端感知层、中间桥接层和联合后端层。

从整体上看，系统由三层组成。第一层是前端感知层：原始 LiDAR 点云 /kitti/velo/pointcloud 与 IMU /kitti/oxts/imu 同时送入 FAST-LIO 与 PointPillars。第二层是中间桥接与跟踪层：fastlio_pose_bridge.py 将 FAST-LIO 输出转换为 MCTrack 可消费的位姿话题 /mctrack/lidar_pose，MCTrack 则接收检测结果 /detection/lidar_detections 与位姿后输出 /mctrack/tracked_objects。第三层是联合后端层：joint_backend_ego_node.py 同时订阅 /Odometry 与 /mctrack/tracked_objects，构建 ego-only 滑窗优化，最终输出 /joint_backend/odom。

系统的主数据流可以概括为以下 7 步：

1. 原始 LiDAR/IMU 进入 FAST-LIO 与 PointPillars；
2. PointPillars 输出标准化的 Detection3DArray；
3. FAST-LIO 输出 /Odometry 与 /Odometry_imu_predicted；
4. Pose bridge 将 /Odometry 转换为 /mctrack/lidar_pose；
5. MCTrack 基于检测与位姿完成关联、轨迹更新和速度估计；
6. 跟踪结果反向馈入 FAST-LIO 做动态点降权；
7. 跟踪结果同时进入联合后端，进一步修正自车轨迹。

2.1 FAST-LIO 前端




图 2: FAST-LIO2 前端架构。项目在点云预处理链路中接入来自 MCTrack 的目标信息，实现动态点自适应降权。

FAST-LIO 是整个系统的定位主干，也是第二章数据流中的起点。它直接消费 KITTI rosbag 中的 LiDAR 点云与 IMU 数据，内部采用 LiDAR-inertial 紧耦合估计思路输出稳定的自车位姿。在本项目中，FAST-LIO 不仅负责生成全局一致的 /Odometry，还同步输出 /Odometry_imu_predicted 作为高频预测位姿，从而为后续跟踪与后端优化提供统一参考。

从模块职责看，FAST-LIO 在本系统中承担三项任务。第一，它为 MCTrack 提供可靠的 ego pose，使 3D 检测框能够在跨帧关联时先完成自车运动补偿。第二，它为联合后端提供原始里程计约束，保证后端优化不会偏离前端估计过远。第三，它通过 preprocess.cpp 接收 /mctrack/tracked_objects，把目标速度、加速度、分数和包围盒信息转化为点级权重，实现“跟踪反哺定位”的前端闭环。

为了把 FAST-LIO 输出送入跟踪模块，项目额外实现了 fastlio_pose_bridge.py。该桥接节点将 /Odometry 转换成 MCTrack 可直接消费的 /mctrack/lidar_pose，从而把原本偏定位侧的里程计消息，转化为检测与跟踪链路中的统一位姿输入。因此，第二章中的 FAST-LIO 不应只被理解为一个独立里程计前端，而应被看作整个闭环系统的时空参考中心；第四章讨论的动态权重优化，本质上正是建立在这一前端之上的增强机制。

2.2 PointPillars 检测模块

PointPillars 通过 MMDet3D/local/ros/nodes/kitti_pointpillars_bag_node.py 封装为 ROS 节点，能够直接消费 rosbag 中的 KITTI 点云。它的职责并不是单纯输出原始检测框，而是为整个系统提供统一、可追踪、带时间戳的 3D 检测消息。项目在 catkin_ws/src/ME5400/msg/Detection3D.msg 和 Detection3DArray.msg 中定义了统一消息格式，包含帧号、类别、置信度、2D 框、3D 尺寸、LiDAR 坐标系位置和航向角等字段。这样一来，PointPillars 与 MCTrack 之间不需要依赖第三方框架的私有格式，而是通过项目统一定义的消息接口连接。

从工程角度看，这一设计有三点作用。第一，节点会读取 KITTI 标定信息，保证

检测结果和坐标变换过程一致。第二，它保留了较低的检测置信度门限，让更多候选框交由后续跟踪器与门控机制处理，而不是在检测端过早裁剪。第三，统一消息结构使同一套检测输出既能送入 MCTrack，也能用于离线 feeder、可视化和结果回放。

2.3 MCTrack 模块与数据流细节




图 3: MCTrack 3D MOT 框架示意。其输出不仅包含位置和尺寸，还包含速度、加速度和轨迹长度等信息。

MCTrack 在线节点实现于 `catkin_ws/src/ME5400/scripts/mctrack_online_node.py`。它默认订阅 `/mctrack/lidar_pose` 和 `/detection/lidar_detections`，内部维护位姿缓冲区与待处理检测队列，在拿到合适时间戳的位姿后再处理检测结果。这种“检测等待位姿、位姿驱动处理”的方式避免了纯按到达顺序处理造成的错时关联。

MCTrack 输出的话题包括可视化用的 `/mctrack/markers` 和真正参与后续优化的 `/mctrack/tracked_objects`。其中 `TrackedObject.msg` 除了包含目标的姿态和尺寸外，还额外记录了 `track_length`、`velocity`、`velocity_fusion`、`velocity_diff`、`velocity_curve` 和 `acceleration` 等信息。这些字段对本项目非常关键，因为后续的动态权重优化和联合后端门控都依赖这些运动属性，而不仅仅是目标框的位置。

因此，第二章要强调的一点是：PointPillars 和 MCTrack 在本系统中并不是单纯的“检测器”和“跟踪器”，而是整个数据流中负责生成对象级几何与运动语义的核心模块。FAST-LIO 提供稳定的 ego pose，PointPillars 提供时序化 3D 检测，MCTrack 进一步把这些检测转化为可持续传播的轨迹状态，最后才使动态权重与联合后端真正具备可实现基础。

3 代码设计：离线 / 在线系统

3.1 整体代码组织

项目通过 Scripts/、catkin_ws/src/ME5400/scripts/ 和 catkin_ws/src/fast_lio/ 三层目录组织代码：顶层脚本负责一键启动和实验调度，ME5400 包负责 ROS 侧桥接、跟踪、后端和 recorder，FAST-LIO 包负责定位前端及动态权重逻辑。表 2 给出当前最关键的入口文件。

表 2: 在线 / 离线系统的主要代码入口。

模块	主要文件	作用
在线基线	Scripts/run_baseline.sh; Scripts/fastlio/run_fastlio_baseline.txt。	启动纯 FAST-LIO 基线并输出 trajectory.txt。
在线优化	Scripts/run_optimized_run_pointpillars_node; run_mctrack_online_node; run_joint_backend_ego.sh	启动 PointPillars、MCTrack、动态权重 FAST-LIO 和联合后端，输出 trajectory.txt 与 trajectory_joint.txt。
一键在线对比	Scripts/run_all.sh	先跑基线，再跑优化流程，并把日志归档到 Results/<seq>_results/Online/full_run.log。
离线双轨实验	Scripts/run_offline_async_offline_bag_feeder.py	通过异步 feeder 运行离线基线与离线联合系统，输出 Offline 目录中的轨迹与日志。
评估与归档	Scripts/evaluation/evaluate_odom_to_tum_recorder.py	生成 trajectory.txt、metrics.json、evaluation_result.png、evaluation_joint_backend.png 和 ablation_bar.png。

3.2 在线系统设计

在线模式下，run_all.sh 会顺序执行 run_baseline.sh 与 run_optimized.sh。前者只启动 roscore、FAST-LIO 和 rosbag 播放，生成纯定位基线；后者则额外启动 PointPillars、MCTrack、FAST-LIO 的 both 模式以及联合后端，并通过 odom_to_tum_recorder.py 同时记录优化后的前端轨迹与后端轨迹。这样的双轨设计直接保证了“同一 bag、同一环境、同一评估脚本”下的公平对比。

在线优化脚本的代码流程非常清晰：先启动 PointPillars；再启动 MCTrack，等待其准备好接收位姿与检测；随后启动开启动态权重的 FAST-LIO；最后启动联合后端并记录 /joint_backend/odom. rosbag 播放完成后，脚本将 trajectory.txt、trajectory_joint.txt 和各类图表统一归档到 Results/<seq>_results/Online/。这套代码设计的优点是依赖关系显式、启动顺序固定、结果目录统一，缺点则是系统仍然是 topic 级松耦合，模块之间共享的是消息而不是统一图状态。

3.3 离线系统设计

离线模式的核心不是简单把在线脚本慢速重跑, 而是通过 `offline_bag_feeder.py` 实现半同步调度。该节点会读取 bag 中的原始 LiDAR/IMU 数据, 发布 `/clock`, 并在每一帧 LiDAR 后等待检测、跟踪或里程计结果达到条件才继续推进仿真时间。它可以分别配置 `require_detection`、`require_tracking`、`require_odom`, 并通过 `timeout_det`、`timeout_track`、`timeout_odom` 控制超时策略。因此, 即便 PointPillars 推理较慢或下游处理偶尔抖动, 整个离线流程也不会因为 rosbag 自顾自播完而失去对齐关系。

更重要的是, 离线 feeder 还把 raw LiDAR 和 gated LiDAR 区分开来: FAST-LIO 持续读取原始点云流, PointPillars 则可以读取更受控的 gated 点云流。这一点正是 `run_offline_all.sh` 中离线双轨实验可稳定运行的关键。脚本会先执行离线基线阶段, 再执行离线联合阶段, 最后调用统一评估脚本输出 Offline 目录下的三类图像和指标文件。

3.4 结果归档与可复现实验链路

不论在线还是离线, 项目最终都会把关键文件整理到 `Results/<seq>_results/<mode>/`。其中轨迹文件、日志文件、图像文件和 `metrics.json` 的命名规则是统一的, 这使报告撰写和后续批量分析变得非常直接。对课程项目而言, 这种“能跑起来”和“能稳定复现结果”同样重要, 而本项目在代码设计层面最大的优点恰恰是形成了完整的运行闭环。

4 动态权重优化

4.1 设计动机与代码位置

动态权重优化的核心思想是: 不再把目标框内的点云简单二值删除, 而是根据目标的运动状态和可信度连续降低这些点的贡献。这样既能减少动态目标对定位的污染, 又不会像硬剔除那样一次性损失所有局部几何信息。当前实现主要位于 `catkin_ws/src/fast_lio/src/preprocess.cpp`, FAST-LIO 在接收到 `/mctrack/tracked_objects` 后, 会将每个目标转成内部的 `DynamicObject`, 其中包含目标中心、包围盒半尺寸、局部航向角、时间戳和权重。

与历史版本相比, 当前代码中动态权重的默认参数已经明确固定为:

- 速度参考值 $v_{\text{ref}} = 10.0$;
- 加速度参考值 $a_{\text{ref}} = 4.0$;
- 速度惩罚系数 $\alpha_v = 0.5$;

- 加速度惩罚系数 $\alpha_a = 0.3$;
- 检测分数惩罚系数 $\alpha_s = 0.2$;
- 最小权重 $w_{\min} = 0.2$;
- 包围盒边界冗余 $xy = 0.5 \text{ m}, z = 0.5 \text{ m}$;
- 对象超时 1.0 s , 最小轨迹长度阈值为 3。

4.2 权重计算方式

设某个被跟踪目标的速度、加速度和检测分数分别为 v 、 a 、 s ，则代码首先对这些属性归一化：

$$\hat{v} = \text{clamp}\left(\frac{v}{v_{\text{ref}}}\right), \quad \hat{a} = \text{clamp}\left(\frac{a}{a_{\text{ref}}}\right), \quad \hat{s} = \text{clamp}(s). \quad (1)$$

随后构造惩罚项

$$p = \alpha_v \hat{v} + \alpha_a \hat{a} + \alpha_s \hat{s}, \quad (2)$$

并得到动态权重

$$w = \text{clip}(1 - p, w_{\min}, 1). \quad (3)$$

这意味着目标越快、加速度越大、检测分数越高，系统越相信它是“真实且强动态”的目标，于是会分配更小的点权重。相反，如果目标轨迹很短、速度接近零或检测分数不高，系统会倾向于保留更高的点权重，避免对静态或不稳定对象过度惩罚。

4.3 权重如何注入 FAST-LIO

权重真正生效的位置是点云预处理。对于每个输入点，系统会调用 `computePointWeight()` 检查该点是否落入任一动态目标包围盒中；若是，则把该点的 `intensity` 更新为原始强度和动态权重的较小值。这样做的好处是无需重写 FAST-LIO 主体数据结构，就能沿用现有点结构把权重一路传递到后续映射和残差计算链路。

相比“删除动态点”，这种软降权有两个直接优势。第一，它对包围盒边缘误差、检测框抖动和部分动态区域更鲁棒，不会因为一次检测偏差直接丢失所有点。第二，它允许系统根据目标运动属性连续调节，而不是把动态点处理成非黑即白的二值逻辑。当前实验结果也说明，真正稳定的增益主要来自这一模块与 MCTrack 的组合，而不是后续后端。

5 联合后端优化

5.1 ego-only 滑窗优化问题

联合后端实现于 `catkin_ws/src/ME5400/scripts/joint_backend_ego_node.py`, 配置文件为 `catkin_ws/src/ME5400/config/joint_backend_ego.yaml`。它的设计是“尽量低成本地验证对象信息能否帮助自车定位”：只优化自车状态，不优化目标状态。当前配置文件给出的关键参数为：窗口长度 8 帧、对象因子系数 $\lambda_{\text{obj}} = 0.12$ 、分数阈值 0.6、轨迹长度阈值 5、最大允许时间差 0.1 s、最大速度突变 2.0 m/s、对象最小权重 0.03、鲁棒核为 Huber、尺度为 0.5；若 `/Odometry` 协方差无效，则回退到 `[0.20, 0.20, 0.10]`。

窗口中的优化变量写作

$$\mathbf{p}_i = [x_i, y_i, \psi_i]^\top, \quad (4)$$

即每帧只保留平面位置和偏航角。这种设计没有把目标状态并入统一变量集，因此计算量小、实现简单、易于在线运行，但代价是目标误差不能被共同估计，只能作为外部观测输入。

5.2 残差建模与门控策略

联合后端包含两类主要残差。第一类是里程计一致性残差：FAST-LIO 的相邻帧相对位姿被视为滑窗的主约束，保证优化结果不会偏离原始里程计太远。第二类是对象观测一致性残差：对于每一帧，通过时间戳最近邻搜索匹配到对应的跟踪快照，并只保留满足分数、轨迹长度、速度突变和时间同步门控的目标。对每个保留目标，代码先利用目标速度把其世界坐标外推到当前帧时间，再投影到优化中的自车局部坐标系下，得到预测观测 z_{ik}^{pred} ；真实观测 z_{ik}^{meas} 则来自 `TrackedObject` 中的 LiDAR 局部姿态，于是对象残差可写为

$$r_{ik}^{\text{obj}} = z_{ik}^{\text{pred}} - z_{ik}^{\text{meas}}. \quad (5)$$

整个优化目标为

$$\min_{\{\mathbf{p}_i\}} \sum_{i=2}^N \|r_i^{\text{odom}}\|_{W_i}^2 + \sum_{i=1}^N \sum_{k \in \mathcal{V}_i} w_{ik} \rho(\|r_{ik}^{\text{obj}}\|_2^2), \quad (6)$$

其中 $\rho(\cdot)$ 是 Huber 或 Cauchy 鲁棒核， $\mathcal{V}_i$ 表示门控通过的目标集合。当前代码中对象因子权重大致写成

$$w_{ik} = \max\left(w_{\min}^{\text{obj}}, \sqrt{\lambda_{\text{obj}}} \cdot (0.5 \hat{s}_{ik} + 0.5 \hat{\ell}_{ik})\right), \quad (7)$$

即由分数归一化和轨迹长度归一化共同决定。

5.3 联合后端的价值与局限

这个后端的工程价值在于，它验证了一个关键命题：即使目标状态不作为显式优化变量，稳定的跟踪目标仍可以作为临时移动锚点，对自车轨迹施加额外约束。换句话说，它已经跨出了“动态目标只是要过滤掉的噪声”这一步。

但局限也非常明确。由于目标状态来自跟踪器的点估计并通过速度传播外推，只要目标速度、检测框或关联结果带噪，噪声就会被重新带回自车位姿。当前实验中，联合后端在部分序列上确实能继续降低全局漂移，但在另一些序列上也会明显退化。因此，第五章的结论不是“联合后端已经成熟”，而是“联合后端的方向成立，但当前 ego-only 实现仍然是一个待继续打磨的工程原型”。

6 实验数据分析

6.1 实验设置与结果来源

本报告实验部分统一采用当前 Results/ 目录中的可复核结果。在线实验包括 9 个序列：0003、0006、0007、0009、0010、0012、0013、0017、0020；离线实验包括 2 个序列：0009、0020。所有数值均来自各目录下的 metrics.json，图像则对应 evaluation_result.png、evaluation_joint_backend.png 和 ablation_bar.png。

在线模式比较三种配置：Baseline、FAST-LIO+MCTrack 和 Joint Backend。离线模式比较三种配置：Baseline(Offline, NoWeight)、FAST-LIO+MCTrack(Offline) 和 JointOffline。评价指标包括 ATE RMSE、RPE RMSE、KITTI 相对平移误差 Tr 和相对旋转误差 Rot。对于 0012 和 0017，这两个序列的有效匹配里程过短，因此 KITTI 分段误差记为 N/A。




图 4: KITTI 数据采集平台。本文所有实验均基于 KITTI Tracking 归档结果。

6.2 在线实验：全量结果汇总

表 3 汇总了所有在线序列的 ATE/RPE。可以看到，FAST-LIO+MCTrack 在 9/9 个序列上全部优于 Baseline，说明当前系统中最稳定的收益来自前端闭环；而 Joint Backend 只在 5/9 个序列上进一步降低 ATE，稳定性明显不足。

表 3: 在线实验 ATE/RPE 汇总。改进百分比相对 **Baseline** 计算，正值表示误差下降。

序列	Baseline ATE	F+M ATE	F+M 改进	Joint ATE	Joint 改进	RPE RMSE (B/F/J)
0003	0.5294	0.4513	+14.75%	0.5875	-10.98%	0.2049 / 0.1809 / 0.2393
0006	0.5238	0.4710	+10.09%	0.5576	-6.45%	0.1324 / 0.0869 / 0.1677
0007	2.3128	2.2393	+3.18%	2.2393	+3.18%	0.1716 / 0.1683 / 0.1683
0009	1.6831	1.6675	+0.93%	3.3082	-96.56%	0.1787 / 0.1651 / 1.9514
0010	3.7651	0.8680	+76.95%	0.9632	+74.42%	0.2774 / 0.2281 / 0.2334
0012	0.0099	0.0092	+7.59%	0.0606	-509.94%	0.0023 / 0.0025 / 0.0076
0013	0.6047	0.5816	+3.82%	0.5816	+3.82%	0.1495 / 0.1392 / 0.1392
0017	0.0411	0.0400	+2.55%	0.0400	+2.55%	0.0029 / 0.0020 / 0.0020
0020	11.7323	6.7938	+42.09%	6.8829	+41.33%	0.2250 / 0.2245 / 0.2270

表 4 给出了在线模式下的 KITTI 相对平移误差与旋转误差。对于有足够分段长度的 7 个序列，FAST-LIO+MCTrack 在 6 个序列上优于基线，而 Joint Backend 仅在 3 个序列上优于基线。这说明当前后端更像一个“有时能帮助纠正全局漂移的附加器”，还不是一个稳定的局部精修器。

表 4: 在线实验 KITTI 相对误差汇总。Rot 以 deg/100m 给出，顺序仍为 Baseline / F+M / Joint。

序列	Baseline Tr(%)	F+M Tr(%)	F+M 改进	Joint Tr(%)	Joint 改进	Rot (B/F/J)
0003	1.4794	1.3516	+8.63%	1.6856	-13.94%	1.1509 / 1.1569 / 1.3699
0006	4.1614	4.0605	+2.42%	4.3990	-5.71%	12.8416 / 11.6291 / 16.0675
0007	3.9042	3.9267	-0.57%	3.9267	-0.57%	4.9702 / 5.0234 / 5.0234
0009	2.5630	2.5281	+1.36%	4.2200	-64.65%	3.2425 / 3.2294 / 3.7550
0010	1.3884	0.9773	+29.61%	1.1140	+19.76%	1.1274 / 1.1368 / 1.5713
0012	N/A	N/A	N/A	N/A	N/A	N/A
0013	2.4374	2.3741	+2.60%	2.3741	+2.60%	2.3026 / 2.2419 / 2.2419
0017	N/A	N/A	N/A	N/A	N/A	N/A
0020	3.2245	2.3967	+25.67%	2.4302	+24.63%	1.1894 / 1.1748 / 1.2326

在线结果中，最强的两个成功序列是 0010 与 0020。0010 的 ATE RMSE 从 3.7651 m 大幅降到 0.8680 m，改善 76.95%；0020 则从 11.7323 m 降到 6.7938 m，改善 42.09%。这两个序列共同说明：当基线漂移明显、动态目标参与较高时，动态点降权与稳定跟踪可以显著改善结果。图 5 给出了序列 0020 的代表性在线结果图。




图 5: 序列 0020 在线模式的代表性结果。红线 FAST-LIO+MCTrack 明显比蓝线基线更贴近真值。

6.3 离线实验：全量结果汇总

离线结果见表 5。0020 仍然是显著成功案例：FAST-LIO+MCTrack(Offline) 将 ATE RMSE 从 12.4796 m 降至 7.1313 m，改善 42.86%；JointOffline 也达到 39.88% 改善，并同步降低 KITTI Tr 与 Rot。0009 的情况则完全不同：离线前端和后端都没有带来明显收益，三条轨迹整体接近，说明在该序列中动态目标提供的额外约束并不足以抵消模型误差。

表 5: 离线实验汇总。RPE、Tr、Rot 列按 Baseline / F+M / Joint 顺序给出。

序列	Baseline ATE	F+M ATE	F+M 改进	Joint ATE	Joint 改进	RPE	Tr(%)	Rot
0009	1.9092	1.9684	-3.10%	1.9355	-1.37%	0.1815 / 0.1686 / 0.1831	3.0287 / 3.1639 / 3.1295	1.4441 / 1.4191 / 1.4131
0020	12.4796	7.1313	+42.86%	7.5024	+39.88%	0.2498 / 0.2321 / 0.8503	3.1171 / 2.2572 / 2.3445	0.7383 / 0.6589 / 0.6730




图 6: 序列 0020 离线模式的联合评估图。后端可继续纠正全局轨迹，但局部 RPE 仍会出现峰值。

6.4 综合分析 with 失败模式

综合全部当前结果，可以得到三个比较清楚的结论。

第一，真正稳定的收益来自前端闭环。在线 9 个序列中，FAST-LIO+MCTrack 在 9/9 个序列上都优于基线；在线 KITTI Tr 在 6/7 个可评估序列上改善；离线 0020 也给出同样结论。这说明本项目中最成熟、最可信的模块是“位姿辅助跟踪 + 跟踪反哺动态权重”的闭环。

第二，联合后端目前仍然脆弱。当前归档结果里的典型失败序列不是旧版本中的 0011，而是 0009 和 0012。0009 在线模式下，Joint Backend 的 ATE RMSE 从 1.6831 m 退化到 3.3082 m；0012 在线模式下则从 0.0099 m 退化到 0.0606 m。它们说明只要目标速度传播、时间对齐或门控条件稍有偏差，ego-only 后端就可能把噪声重新注入自行车轨

迹。

第三，当前后端更像“长时漂移纠偏器”而不是“通用局部精修器”。无论是在线 0020 还是离线 0020，联合后端都更多表现为维持或部分强化全局轨迹的改进，而不是稳定降低每一帧的局部 RPE。换句话说，第六章的实验结论并不是“联合后端已经完成”，而是“联合后端方向成立，但当前实现还需要更强的激活策略和更鲁棒的对象建模”。


7 结论与未来计划 (Conclusion / Future Plan)

本报告按照你指定的 7 个章节重新组织了整个项目内容，并把原有的背景、系统设计、工程实现、动态权重和联合后端细节全部补回正文，同时将当前仓库中的所有实验结果和全部结果图完整纳入文档。系统层面的核心结论非常明确：本项目已经成功构建了一条围绕 FAST-LIO、PointPillars 和 MCTrack 的双向协同闭环，其中最稳定、最可靠的收益来自前端动态权重闭环，而不是当前版本的 ego-only 联合后端。


未来工作建议集中在三条主线。第一，给联合后端加入自适应激活机制，只在跟踪稳定、目标数量充足、基线存在明显漂移时才开启对象约束。第二，把目标状态纳入统一优化变量，而不是停留在 ego-only 形式。第三，从目标框级约束进一步走向目标刚体表面约束，把动态车辆真正从“干扰源”转化为“移动路标”。如果这些方向能够继续推进，本项目就有机会从课程级工程闭环系统，进一步演进为具备更强研究贡献的 object-centric LiDAR-inertial 联合优化框架。

A 在线实验全量图片


本节按序列插入全部在线结果图，每个序列均包含在线前端对比图、联合后端评估图和柱状对比图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 7: 序列 0003 的在线实验完整结果图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 8: 序列 0006 的在线实验完整结果图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 9: 序列 0007 的在线实验完整结果图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 10: 序列 0009 的在线实验完整结果图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 11: 序列 0010 的在线实验完整结果图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 12: 序列 0012 的在线实验完整结果图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 13: 序列 0013 的在线实验完整结果图。



(a) 在线前端对比




(b) 联合后端评估




(c) ATE/RPE 柱状对比


图 14: 序列 0017 的在线实验完整结果图。



(a) 在线前端对比



(b) 联合后端评估



(c) ATE/RPE 柱状对比


图 15: 序列 0020 的在线实验完整结果图。

B 离线实验全量图片


本节插入全部离线结果图，每个序列均包含离线三轨迹对比图、联合后端评估图和柱状对比图。

参考文献


- [1] W. Xu, Y. Cai, D. He, J. Lin, and F. Zhang, “FAST-LIO2: Fast direct LiDAR-inertial odometry,” *IEEE Transactions on Robotics*, vol. 38, no. 4, pp. 2053–2073, 2022.
- [2] A. H. Lang, S. Vora, H. Caesar, L. Zhou, J. Yang, and O. Beijbom, “PointPillars: Fast encoders for object detection from point clouds,” in *Proc. CVPR*, 2019, pp. 12697–12705.
- [3] A. Geiger, P. Lenz, and R. Urtasun, “Are we ready for autonomous driving? The KITTI vision benchmark suite,” in *Proc. CVPR*, 2012, pp. 3354–3361.
- [4] X. Weng, J. Wang, D. Held, and K. Kitani, “3D multi-object tracking: A baseline and new evaluation metrics,” in *Proc. IROS*, 2020, pp. 10359–10366.



(a) 离线三轨迹对比




(b) 离线联合评估




(c) ATE/RPE 柱状对比


图 16: 序列 0009 的离线实验完整结果图。



(a) 离线三轨迹对比



(b) 离线联合评估



(c) ATE/RPE 柱状对比

图 17: 序列 0020 的离线实验完整结果图。